

MoodTrackAI: Inovação em Análise Emocional Multimodal

Sistema avançado de monitorização de bem-estar emocional desenvolvido na Universidade do Minho.

Rodrigo, Tomás e Nuno

Grupo 2



A computação afetiva como pilar do bem-estar digital



Modelo de Ekman e a Classe Neutra

O sistema utiliza as 6 emoções básicas validadas na literatura, com a adição de uma 7ª classe para captar a rotina e evitar classificações forçadas.



Captura de Dados e Pipeline STT

A qualidade da transcrição é crítica, pois erros semânticos comprometem a análise emocional posterior.

Modelo	Tempo de Inferência	Qualidade em PE	Observações
Whisper Small	~3.4s	Baixa	Erros como "olhos" em vez de "áudios"
Whisper Medium	~8.5s	Elevada	Alta qualidade mas latência proibitiva
Whisper Large-v3-turbo	~6.4s	Excelente	Sem erros semânticos relevantes

Análise Textual: LLM e Baselines

Evolução da performance semântica em Português Europeu

Limitações do XLM-RoBERTa

A baseline Zero-Shot revelou rigidez lógica e dificuldade com a ironia e coloquialidade do PT-PT, atingindo apenas 14% de accuracy.

Transcrição para Qwen2.5-3B

Adoção de um LLM local via Ollama, permitindo capacidade de raciocínio profundo (reasoning) sobre relatos abertos em vez de simples inferência rígida.

Light Ensemble Disambiguated

Estratégia inovadora que funde critérios léxicos com análise de valência e evento, corrigindo confusões entre emoções negativas próximas.

Salto de Desempenho (76.4%)

A abordagem multimodal textual elevou a precisão para 0.764 num benchmark rigoroso de 250 textos, validando a superioridade dos LLMs.

Análise Prosódica e Dados Acústicos

Para a análise vocal, o MoodTrackAI utiliza embeddings acústicos que capturam a essência do tom de voz para além das palavras.

01

Embeddings Latentes

Utiliza o microsoft/wavlm-base para extrair vetores de 1536 dimensões que representam o timbre e ritmo.

02

Classificador SVC

Um modelo de Support Vector Machine com kernel RBF, treinado em datasets de referência como RAVDESS e CREMA-D

03

Métricas Físicas

Acompanhamento de pitch (Hz), energia (RMS) e taxa de fala para diagnóstico complementar.

04

Desempenho Robusto

Alcançou um F1-Macro de 61.5% em validação cruzada, demonstrando alta capacidade de generalização vocal.

Estratégia de Late Fusion (70% Texto / 30% Áudio)

Valência vs. Arousal

O texto transporta a valência emocional (o quê é expresso), enquanto a prosódia transporta a intensidade e o arousal (como é expresso).



Estabilidade e Variância

Os modelos prosódicos têm grande variância inter-locutor. O maior peso textual minimiza o erro e garante estabilidade estatística.



Estrutura Lógica (Mehrabian adaptado)

Na análise computacional, o texto é o portador de 100% da estrutura lógica; o tom de voz indica a emoção, mas é o texto que explica o motivo.



Model layer


A fusão tardia permite auditar qual modalidade contribuiu mais para a predição e tolerar áudios corrompidos.



Score Final

Orquestração e Recomendações

O MoodTrackAI vai além da análise, oferecendo um motor de recomendações generativo para apoiar a autorregulação emocional.



Interface e Recomendações

O utilizador vê apenas uma UI fluida em Next.js, onde grava o seu diário e recebe os planos de bem-estar gerados pelo Mistral-7B.

Orquestração Assíncrona

A API em Node.js e o BullMQ (Redis) gerem filas de tarefas em background, garantindo que o processamento pesado não bloqueia a aplicação.

Infraestrutura e Dados

Tudo assenta numa rede Docker isolada, com armazenamento biométrico no MinIO (S3) e persistência relacional no PostgreSQL.

Motor Analítico Pesado

O microserviço em Python (FastAPI) faz o trabalho duro: corre o STT Whisper, invoca o Ollama (Qwen2.5) e processa os embeddings WavLM.

Discussão Crítica e Reflexão Ética

Desempenho e Nuances

Joy (0.917) / Neutral (0.972)

Resultados de excelência em relatos positivos. A Tristeza foi identificada como "categoria de fuga", absorvendo valências negativas ambíguas.

Limitações Técnicas (O Desafio)

Domain Shift & Ruído

O modelo acústico (WavLM) treinado em atores pode sofrer domain shift em voz espontânea. O STT Whisper ainda apresenta vulnerabilidade a sotaques regionais.

Viés Algorítmico

Cultura e Coloquialidade

Modelos treinados maioritariamente em conteúdos online (frequentemente anglo-saxónicos) podem subestimar o jargão emocional e coloquialismos típicos de Portugal.

Limites da Interpretação

Ausência de Contexto Clínico

O sistema identifica padrões associados a emoções estatísticas, mas não tem acesso ao contexto subjetivo ou histórico do utilizador.

Considerações Éticas, Conclusão e Futuro

Garantia de privacidade, limites éticos da inteligência artificial no bem-estar e o roteiro de evolução tecnológica.

Privacidade e Segurança

Implementação de execução local (via Ollama e MinIO) para garantir que dados sensíveis de voz nunca sejam enviados a serviços de terceiros.

Uso Responsável

O MoodTrackAI atua como uma ferramenta estatística de apoio ao bem-estar; o sistema não substitui diagnósticos clínicos ou intervenções profissionais.

Conclusão

A arquitetura provou a viabilidade de fundir acústica e semântica localmente. O futuro passa por fine-tuning do WavLM em dados de Portugal e integração Mobile com WebSockets.