

MoodTrackAI: Monitor de Bem-Estar em Diários de Voz com Análise Emocional Multimodal

Tomás Henrique Alves Melo (PG60018)¹, Rodrigo Miguel Granja Ferreira (PG60392)¹, and Nuno Filipe Leite Oliveira Araújo (PG61218)¹

¹ Universidade do Minho

Abstract. Este trabalho descreve a conceção e implementação do MoodTrackAI, uma aplicação de diário emocional em áudio que combina transcrição automática de voz com análise multimodal de emoções. O utilizador grava registos de voz sobre o seu dia; o sistema transcreve automaticamente o conteúdo através do Whisper large-v3-turbo, classifica a dimensão semântica do texto com um Large Language Model local (Qwen2.5-3B via Ollama) e analisa a dimensão vocal através de embeddings acústicos extraídos com WavLM-base e classificados por um modelo SVC com kernel RBF treinado para reconhecimento emocional. As duas modalidades são combinadas por late fusion probabilística, com pesos base de 70% para texto e 30% para áudio, produzindo uma distribuição final sobre sete classes: as seis emoções básicas de Ekman acrescidas da classe neutral. O sistema apresenta tendências diárias, calendário emocional interativo e um motor de recomendações personalizadas de bem-estar. A arquitetura baseia-se em microsserviços orquestrados por Docker Compose, com frontend em Next.js, API REST em Node.js/Express, serviço de análise em Python/FastAPI, PostgreSQL, Redis, MinIO e Ollama.

Keywords: Computação Afetiva · Análise Multimodal · Diário de Voz · Large Language Models · Prompt Engineering · Late Fusion · Bem-Estar Emocional

Declaração de Integridade e Distribuição de Nota

Os intervenientes neste trabalho académico declaram ter atuado com integridade e não ter recorrido a práticas de plágio nem a qualquer forma de utilização indevida de informação ou falsificação de resultados em nenhuma etapa da sua elaboração. Mais declaram conhecer e respeitar o **Código de Conduta Ética da Universidade do Minho**.

A nota é distribuída de forma igual entre todos os elementos do grupo:

Table 1. Distribuição da nota — todos os membros recebem a mesma classificação.

Número	Nome	DELTA
PG60018	Tomás Henrique Alves Melo	1
PG60392	Rodrigo Miguel Granja Ferreira	1
PG61218	Nuno Filipe Leite Oliveira Araújo	1

1 Introdução

1.1 Contextualização

A computação afetiva, definida por Picard [1] como o estudo de sistemas que reconhecem, interpretam e simulam emoções humanas, tem ganho relevância crescente com a proliferação de dispositivos inteligentes e interfaces conversacionais. No contexto do bem-estar pessoal, a capacidade de monitorizar automaticamente o estado emocional de um utilizador ao longo do tempo abre caminho a intervenções preventivas e a estratégias personalizadas de autorregulação.

O **MoodTrackAI** propõe uma abordagem de *journaling* em voz que é menos intrusiva do que questionários estruturados e mais rica em informação do que simples texto escrito, para estimar o estado afetivo diário do utilizador. A análise multimodal (acústica e semântica) permite capturar dimensões complementares da expressão emocional, dado que a prosódia do discurso e o conteúdo verbal transportam sinais distintos sobre o estado interno do locutor [1, 2].

1.2 Motivação

O acompanhamento do bem-estar emocional é um desafio crescente nas sociedades contemporâneas. As soluções existentes como por exemplo questionários clínicos, diários escritos, aplicações de *mood tracking* manual, exigem esforço deliberado, o

que limita a adoção sustentada. O diário de voz é uma alternativa mais natural: o utilizador fala livremente sobre o seu dia (2-5 minutos) e a análise automática elimina o esforço de classificação manual.

A escolha deste problema foi motivada por: (1) a **riqueza multimodal da voz**, que transporta simultaneamente conteúdo verbal e paraverbal; (2) a **aplicabilidade prática imediata**, sem hardware especializado; e (3) a **pertinência científica**, dado que sistemas end-to-end de análise emocional em PE são escassos.

1.3 Objetivos

1. **Captura de voz:** permitir ao utilizador gravar registos áudio curtos sobre o seu dia, sem estrutura predefinida.
2. **Transcrição automática (STT):** converter o áudio em texto usando Whisper, testando diferentes tamanhos de modelo para Português Europeu.
3. **Análise emocional multimodal:** classificar as emoções básicas de Ekman a partir do texto transcrito através de um LLM local (Qwen2.5) e das características prosódicas do áudio.
4. **Fusão e persistência:** combinar os dois vetores emocionais por *late fusion* ponderada e persistir em base de dados.
5. **Visualização de tendências:** gráficos de evolução emocional e calendário interativo com a emoção dominante por dia.
6. **Motor de recomendações:** sugestões personalizadas de atividades de bem-estar com base no perfil emocional diário.
7. **Reflexão ética:** discutir implicações de privacidade, consentimento e viés algorítmico.

1.4 Contribuições do Trabalho

1. Desenvolvimento de um sistema multimodal de análise emocional aplicado a diários de voz em Português Europeu.
2. Integração de análise textual e prosódica através de uma estratégia de **late fusion** interpretável.
3. Implementação de um motor de inferência local baseado em LLMs (Ollama) com estratégia de **prompt ensemble** para análise emocional em PE.
4. Arquitetura distribuída baseada em microserviços e Docker Compose.
5. Sistema de recomendações emocionais totalmente generativo baseado em LLMs.

2 Problema e Modelo Emocional

2.1 Problema Escolhido

O sistema pretende estimar automaticamente o estado emocional do utilizador a partir de entradas de voz espontâneas, produzindo recomendações adaptativas de bem-estar e visualizações emocionais longitudinais.

2.2 Domínio de Aplicação

O MoodTrackAI enquadra-se no domínio da monitorização de bem-estar emocional e interação humano-computador adaptativa, utilizando sinais de áudio e linguagem natural para inferir estados afetivos.

2.3 Modelo de Ekman + Neutral

O sistema assenta no modelo das **seis emoções básicas** de Ekman [3] — alegria (*joy*), tristeza (*sadness*), raiva (*anger*), medo (*fear*), nojo (*disgust*) e surpresa (*surprise*) — por ser o modelo de categorização emocional mais amplamente validado em computação afetiva [4]. Cada classe é representada como um valor contínuo em $[0, 1]$, formando uma distribuição emocional de sete dimensões por entrada de diário.

A inclusão de **neutral** foi também essencial para evitar que relatos factuais, rotineiros ou emocionalmente pouco marcados sejam forçados artificialmente para uma das seis emoções básicas. Assim, cada entrada de diário é representada como uma distribuição probabilística sobre sete classes, permitindo identificar tanto emoções expressivas como estados afetivos neutros.

2.4 Justificação do Modelo Emocional

A escolha do modelo de Ekman deve-se à sua simplicidade interpretativa, ampla validação experimental e adequação a tarefas de classificação emocional discreta. No entanto, em diários de voz espontâneos, muitos relatos são meramente descritivos ou rotineiros, não exprimindo uma emoção dominante clara. Por esse motivo, a classe neutral foi acrescentada como categoria complementar.

Esta decisão melhora a robustez do sistema, evitando classificações artificiais forçadas em casos não marcados emocionalmente (e.g., “Acordei, fui trabalhar e voltei para casa”). A classe neutral não substitui o modelo de Ekman; funciona como extensão prática para cenários reais de journaling emocional.

Na camada de apresentação (Interface de Utilizador), os scores visíveis correspondem estritamente às seis emoções básicas de Ekman. A 7ª classe calculada internamente (neutral) atua como um sumidouro matemático que absorve a probabilidade residual quando nenhuma emoção é fortemente identificada. Dado que a neutralidade não constitui em si uma emoção primária reportável ou acionável, a interface omite esta classe.

3 Dados e Pré-Processamento

3.1 Dados de Áudio

O sistema utiliza gravações de voz espontâneas produzidas diretamente pelos utilizadores através da interface web. Os registos contêm descrições livres do dia-dia, emoções, acontecimentos e reflexões pessoais.

3.2 Pipeline de Transcrição — Whisper

O sistema utiliza o modelo **Whisper** [5], disponível em múltiplos tamanhos. Para selecionar a configuração final, foram comparadas três variantes — `small`, `medium` e `large-v3-turbo` — sobre dois áudios gravados em Português Europeu, correspondentes a relatos espontâneos semelhantes aos usados na aplicação. Em vez de avaliar apenas a velocidade, a comparação considerou também a gravidade dos erros de transcrição, uma vez que o texto transcrito é posteriormente usado pelo modelo emocional textual. Assim, erros que alteram palavras semanticamente importantes são mais problemáticos do que pequenas diferenças de pontuação, artigos ou normalização ortográfica.

Textos usados como teste:

A1: “Hoje acordei por volta das oito da manhã e comecei o dia com alguma calma. Tomei o pequeno-almoço, organizei a mochila e depois fui tratar de algumas tarefas da faculdade. Durante a manhã estive a fazer apontamentos, respondi a algumas mensagens e tentei adiantar trabalho que tinha pendente. À tarde fui dar uma volta para espairecer, bebi um café e ainda aproveitei para pensar melhor no que tenho de fazer nos próximos dias. No geral, foi um dia normal, mas senti que consegui ser produtivo e manter alguma organização.”

A2: “O meu dia foi um bocado mais cheio do que eu estava à espera. Comecei por tentar resolver umas coisas no computador, mas acabei por perder mais tempo do que queria porque apareceram alguns erros. Depois almocei, voltei ao trabalho e tentei focar-me outra vez. À tarde gravei alguns áudios para testar modelos de transcrição automática e perceber qual deles consegue reconhecer melhor a minha fala em português. No fim do dia senti-me um pouco cansado, mas também satisfeito porque consegui avançar em várias coisas importantes.”

Table 2. Comparação qualitativa e temporal dos modelos Whisper em dois áudios de teste

Áudio	Modelo	Tempo	Erros relevantes observados
A1	small	3.73s	espairecer transcrito como “ espair ser ”; menor qualidade linguística geral.
A1	medium	9.12s	espairecer transcrito como “ espirecer ”; boa estrutura frásica, mas maior latência.
A1	large-v3-turbo	6.71s	Sem erros semanticamente relevantes; apenas diferenças menores de pontuação, artigos e normalização.
A2	small	3.19s	áudios transcrito como “ olhos ”; “ Há tarde ” em vez de “À tarde”; repetição “ mas mas ”.
A2	medium	7.96s	Transcrição quase integralmente correta; pequena omissão em “avançar em várias coisas importantes”.
A2	large-v3-turbo	6.18s	Transcrição semanticamente correta; apenas a repetição residual “ mas mas ”.

No primeiro áudio, todos os modelos preservaram o conteúdo geral do relato, mas o `small` e o `medium` falharam a palavra “espairecer”, relevante para a naturalidade da transcrição. O `large-v3-turbo` produziu a versão mais próxima do original, mantendo o significado do relato sem erros semanticamente importantes.

No segundo áudio, as diferenças foram mais evidentes. O `small` introduziu erros com potencial impacto na análise textual, sobretudo ao transcrever “áudios” como “**olhos**”, o que altera diretamente uma palavra central do relato. O `medium` apresentou elevada qualidade, mas com o maior tempo de inferência. O `large-v3-turbo` manteve qualidade muito próxima do `medium`, com menor tempo, preservando corretamente o conteúdo emocional e factual do relato. A repetição residual “**mas mas**” não altera a interpretação semântica da frase, nem compromete a classificação emocional, sendo por isso considerada um erro superficial.

Conclusão: O `whisper small` é o mais rápido, mas os erros observados tornam-no menos adequado para uma pipeline em que a transcrição alimenta diretamente a análise emocional. O `whisper medium` apresenta boa qualidade, mas com maior latência. A versão final adotou o **Whisper large-v3-turbo**, por oferecer o melhor

compromisso entre qualidade semântica, robustez em Português Europeu e tempo de inferência.

3.3 Pré-Processamento do Texto

Após a transcrição, o texto é normalizado e enviado para o modelo textual de classificação emocional. A versão final não utiliza classificação *zero-shot* baseada em NLI tradicional; em vez disso, recorre a um LLM local, Qwen2.5:3b-instruct, executado via Ollama, com uma estratégia de *prompt ensemble* e pós-processamento semântico.

O texto é analisado em Português Europeu e o modelo devolve uma distribuição probabilística sobre as sete classes emocionais. A resposta é forçada para formato JSON, sendo posteriormente normalizada e validada no backend para garantir robustez contra respostas malformadas do LLM.

3.4 Extração de Features Acústicas e Embeddings WavLM

A componente prosódica do sistema combina duas fontes de informação acústica. Em primeiro lugar, são extraídas características clássicas com **librosa**, usadas para análise interpretável e diagnóstico da fala. Em segundo lugar, a versão final do classificador prosódico utiliza embeddings extraídos com **microsoft/wavlm-base**, posteriormente classificados por um modelo **SVC** com kernel RBF treinado no conjunto de dados emocional utilizado no projeto.

Table 3. Características prosódicas extraídas com librosa e respetiva interpretação afetiva

Feature	Significado afetivo
meanPitchHz, pitchStdDev	Tom médio e variabilidade — tristeza tende a associar-se a pitch mais baixo; excitação, surpresa ou raiva podem apresentar maior variação
meanEnergy, energyStdDev	Intensidade do discurso — emoções de maior ativação, como alegria ou raiva, tendem a apresentar maior energia
speechRate	Taxa de fala — pode aumentar em medo, surpresa ou excitação e diminuir em tristeza
pauseRatio	Proporção de silêncio — hesitação, tristeza ou ansiedade podem apresentar maior presença de pausas
MFCC (13 coef.)	Envelope espectral — captura timbre e qualidade vocal
jitter, shimmer	Irregularidade do pitch e da amplitude — pode indicar tensão vocal ou instabilidade emocional
voicedRatio	Proporção de segmentos com voz ativa

Para a classificação final da emoção vocal, o áudio é convertido para 16 kHz, processado por WavLM-base e representado por um vetor de embeddings de 1536 dimensões, resultante da concatenação de estatísticas de média e desvio-padrão dos estados latentes. Estes embeddings são fornecidos a um classificador SVC com kernel RBF e calibração probabilística, permitindo obter uma distribuição sobre as mesmas sete classes usadas pela componente textual.

3.5 Desafios dos Dados em Português Europeu

- **Qualidade STT em PE:** o Whisper foi treinado maioritariamente em Inglês e Português Brasileiro; erros de transcrição introduzem ruído na análise semântica.
- **Heterogeneidade prosódica:** a mesma emoção manifesta-se de formas acústicas distintas entre locutores, géneros e culturas.
- **Ausência de corpora anotados em PE:** impossibilita avaliação quantitativa rigorosa.
- **Latência:** o processamento completo (STT + prosódia + LLM) exige arquitetura assíncrona para não bloquear a interface.

4 Metodologia e Modelos

4.1 Arquitetura Geral do Sistema

O MoodTrackAI segue uma arquitetura de **microserviços** orquestrados por Docker Compose, ilustrada na Fig. 1.




Fig. 1. Diagrama de arquitetura do sistema MoodTrackAI

4.2 Modelo Textual — LLM Local (Qwen via Ollama)

Para a componente semântica, o sistema transitou de uma abordagem tradicional de classificação **zero-shot** (baseada em modelos da família RoBERTa) para a utilização de um **Large Language Model (LLM)** executado localmente através do motor **Ollama**. O modelo selecionado foi o **Qwen2.5:3b-instruct**, otimizado

para inferência eficiente em hardware de consumo sem comprometer a capacidade de raciocínio lógico em Português.

A classificação emocional é realizada através de uma estratégia concebida neste projeto designada de **Light_Ensemble_Disambiguated**. Esta estratégia parte do **Light_Ensemble**, que combina dois prompts complementares, e acrescenta uma camada conservadora de desambiguação semântica para corrigir confusões recorrentes entre emoções negativas próximas, sobretudo **sadness** vs. **anger** e **sadness** vs. **fear**.

Para evitar a atribuição forçada e artificial de emoções a relatos puramente factuais ou de rotina, a categoria **neutral** foi adicionada aos prompts de classificação. Ao contrário de versões preliminares, a versão final do sistema preserva esta categoria até ao resultado final, permitindo que o frontend apresente também estados neutros.

Estratégia de Prompts (Light_Ensemble_Disambiguated)

A estratégia de fusão de **prompts** divide-se em duas abordagens complementares:

1. Prompt Principal (Focado em Critérios e Desambiguação)

Esta abordagem (com peso de 70%) é fortemente orientada a regras. Fornece ao modelo um dicionário léxico e regras explícitas para separar emoções que frequentemente se confundem no discurso coloquial (ex: medo vs surpresa).

És um classificador de emoções para relatos diários em português europeu.

Objetivo: devolver uma distribuição probabilística pelas 7 classes: joy, sadness, surprise, anger, disgust, fear, neutral.

Critérios principais:

- joy: alegria, satisfação, entusiasmo, orgulho, alívio positivo.
- sadness: perda, vazio, desânimo, choro, sofrimento emocional.
- (...)
- neutral: rotina, relato factual, ausência de emoção dominante.

Distingue especialmente:

- fear vs surprise: fear envolve ameaça/ansiedade; surprise envolve inesperado/espanto.
- anger vs disgust: anger envolve revolta/frustração; disgust envolve repulsa/nojo.
- sadness vs neutral: sadness tem sofrimento/perda; neutral é factual/rotineiro.

Responde apenas com JSON válido, sem explicações.

2. Prompt Analítico (Focado em Raciocínio Estruturado)

Esta abordagem complementar (com peso de 30%) força o modelo a refletir sobre os eventos do texto antes de classificar. Ao pedir-lhe que analise interna-

mente a “valência” e o “evento”, o LLM constrói um contexto mais sólido que previne respostas irrefletidas (alucinações).

Tarefa: classificação emocional de um relato diário transcrito.

Analisa internamente os seguintes aspetos, mas NÃO escrevas a análise:

1. Evento principal do relato.
2. Valência emocional: positiva, negativa ou neutra.
3. Presença de ameaça, perda, injustiça, repulsa ou surpresa.
4. Emoção dominante entre: joy, sadness, surprise, anger, disgust, fear, neutral.

Formato obrigatório da resposta:

```
{"joy": 0.0, "sadness": 0.0, "surprise": 0.0, "anger": 0.0, "disgust": 0.0, "fear": 0.0, "neutral": 0.0}
```

Camada de Desambiguação Semântica

Durante os testes finais verificou-se que o modelo textual, apesar de apresentar bom desempenho global, tendia a classificar alguns relatos negativos ambíguos como **sadness**. Este comportamento é coerente com a análise do classification report, onde **sadness** apresentava recall elevado mas precision inferior.

Para mitigar este problema, foi adicionada uma camada de pós-processamento conservadora. Esta camada só atua quando a distribuição textual coloca **sadness** em primeiro lugar, mas o texto contém marcadores linguísticos fortes de **anger** ou **fear** e estas classes já surgem com probabilidade relevante.

Exemplos de marcadores utilizados:

Table 4. Marcadores usados na desambiguação semântica conservadora

Classe	Marcadores linguísticos
anger	irritado, injustiça, frustrado, revoltado, raiva, falta de respeito
fear	ansiedade, preocupado, insegurança, alerta, perigo, pânico, corpo tenso

Esta regra não substitui o LLM, funcionando apenas como mecanismo de desempate em casos muito específicos. A estratégia mantém a interpretabilidade do sistema e reduz erros observados nos testes finais com áudio real.

Comparação com a Abordagem Inicial (XLM-RoBERTa)

O desenvolvimento inicial do MoodTrackAI recorreu ao **XLM-RoBERTa Large**. Embora teoricamente capaz de classificação *zero-shot* multilingue sem treino explícito, esta arquitetura revelou limitações críticas estruturais durante os testes empíricos da equipa em cenários reais:

- 1. **Rigidez Semântica (Natural Language Inference):** O XLM-RoBERTa baseava-se na hipótese rígida “*This text expresses {emotion}*”. Diários de voz frequentemente contêm ironia, divagações, descrições factuais prolongadas ou mudanças abruptas de tema que quebravam a lógica matemática de inferência do modelo.
- 2. **Ambiguidade e Qualidade em PE:** Num *benchmark* interno conduzido pela equipa com 250 textos (incluindo 50 casos ambíguos gerados em Português Europeu coloquial), o XLM-RoBERTa demonstrou profunda dificuldade em discernir nuances (ex: confundir cansaço físico com tristeza profunda).
- 3. **Melhoria Exponencial:** A transição para o modelo **Qwen2.5:3b** acoplado à estratégia **Light_Ensemble_Disambiguated** resultou numa melhoria substancial da métrica F1-Score do sistema (atingindo 76.5%), suportada pela superior capacidade de raciocínio profundo (**reasoning**) do LLM moderno perante descrições abertas, conforme apresentado na tabela 4.

Table 5. Comparação entre a abordagem inicial (RoBERTa/lexical, n=50) e a abordagem textual baseada em Qwen2.5:3b + Light_Ensemble (n=250). A versão final integrada na aplicação usa esta estratégia como base e acrescenta uma camada conservadora de desambiguação semântica, designada Light\Ensemble_Disambiguated.

Abordagem	Acc.	Top-2	n
Qwen2.5:3b + Light_Ensemble (base textual)	0.764	0.976	250
Lexical Baseline (melhor inicial)	0.540	0.740	50
Embeddings Semânticos (MiniLM)	0.540	0.720	50
DistilRoBERTa fine-tuned (EN)	0.320	0.540	50
XLM-RoBERTa Zero-Shot NLI	0.140	0.280	50

Nota: os valores da tabela correspondem ao benchmark da estratégia textual base Light_Ensemble. A estratégia Light_Ensemble_Disambiguated, usada na versão final da aplicação, acrescenta uma regra conservadora de pós-processamento para casos específicos de confusão entre sadness, anger e fear, tendo sido validada nos testes finais de integração com áudio real.

Table 6. Classification report da estratégia Light_Ensemble (Qwen2.5:3b-instruct, n=250).

Emoção	Precision	Recall	F1-Score	Support
joy	0.917	0.917	0.917	36
sadness	0.493	1.000	0.661	36
surprise	0.750	0.771	0.761	35
anger	0.688	0.629	0.657	35
disgust	1.000	0.600	0.750	35
fear	1.000	0.472	0.642	36
neutral	1.000	0.946	0.972	37
macro avg	0.835	0.762	0.765	250

4.3 Análise do Classification Report

A análise por classe (Tabela 5) revela padrões de erro consistentes com as limitações do modelo. A emoção **sadness** apresenta recall perfeito (1.0) mas precision baixa (0.49), o que indica que o modelo tende a classificar como tristeza relatos negativos ambíguos — como cansaço, frustração leve ou desmotivação — mesmo quando a emoção dominante seria outra. Este comportamento é esperado dado que sadness é a emoção negativa mais genérica do modelo de Ekman, funcionando como “categoria de fuga” para valências negativas não claramente identificadas.

O padrão inverso observa-se em **fear** e **disgust**, com precision=1.0 mas recall baixo (0.47 e 0.60, respetivamente). O modelo é muito conservador nestas classes: só as atribui quando os sinais linguísticos são inequívocos (ex: linguagem de ameaça explícita para fear, repulsa direta para disgust), falhando casos mais subtis ou implícitos. Em contraste, **joy** e **neutral** apresentam F1 elevado (0.917 e 0.972), refletindo que relatos positivos e factuais têm padrões linguísticos mais consistentes e menos ambíguos em Português Europeu.

4.4 Modelo Prosódico — WavLM-base + SVC RBF

A componente prosódica final da arquitetura é baseada em **microsoft/wavlm-base**, um modelo auto-supervisionado para representação acústica da fala. Em vez de depender apenas de features manuais como pitch, energia ou MFCC, o

sistema extrai embeddings latentes do áudio e utiliza estes vetores como entrada para um classificador supervisionado.

O classificador final é um **Support Vector Classifier** com kernel RBF, treinado sobre embeddings WavLM extraídos de um conjunto de dados emocional organizado nas sete classes do sistema: joy, sadness, surprise, anger, disgust, fear e neutral.

Dataset de Treino do Classificador Prosódico

Para o treino do classificador SVC, foi construído um corpus aglomerado a partir de quatro datasets de referência em *Speech Emotion Recognition* (SER):

- **RAVDESS** (Ryerson Audio-Visual Database of Emotional Speech and Song) — um dos datasets mais utilizados na literatura, contém atores profissionais a expressar frases curtas com entoação emocional controlada.
- **CREMA-D** (Crowd-sourced Emotional Multimodal Actors Dataset) — focado na diversidade vocal, gravado por atores de diferentes origens demográficas com diferentes intensidades de expressão emocional.
- **TESS** (Toronto Emotional Speech Set) — áudios de duas atrizes a pronunciar centenas de palavras num conjunto rigoroso de categorias emocionais, com elevada clareza articulatória.
- **SAVEE** (Surrey Audio-Visual Expressed Emotion) — dataset composto por vozes masculinas a expressarem as emoções básicas de Ekman em frases de comprimento variável.

A combinação destas quatro fontes garante diversidade demográfica, diferentes intensidades vocais e robustez acústica na modelação das características extraídas pelo WavLM, mitigando o risco de overfitting a um único estilo ou perfil de locutor.

Representação Acústica

Cada áudio é carregado a 16 kHz e processado por WavLM-base. A representação final tem 1536 dimensões, resultantes da concatenação da média e do desvio-padrão dos embeddings ao longo do tempo. Esta estratégia permite capturar tanto o padrão médio da voz como a sua variabilidade prosódica.

Justificação do Modelo Acústico

A escolha de WavLM-base justifica-se por três razões principais:

1. **Representações robustas da fala:** modelos auto-supervisionados como WavLM aprendem padrões acústicos gerais a partir de grandes quantidades de fala, capturando informação sobre timbre, ritmo, energia e variação temporal.
2. **Melhor capacidade de generalização:** ao usar embeddings latentes em vez de apenas features manuais, o sistema consegue representar padrões vocais mais complexos e menos dependentes de regras fixas.
3. **Integração com classificador probabilístico:** o SVC com kernel RBF permite separar classes emocionais não linearmente e, com `probability=True`, produzir distribuições de probabilidade compatíveis com a late fusion.

As features clássicas extraídas com librosa continuam a ser úteis para interpretação, diagnóstico e eventual fallback, mas a classificação prosódica principal da versão final é realizada pelo pipeline WavLM-base + SVC RBF.

O modelo demonstrou um desempenho altamente competitivo para a área de Speech Emotion Recognition, alcançando um **F1-Macro de 61.5%** na validação cruzada estratificada (Stratified Group K-Fold) ao longo de 7 classes emocionais, comprovando a robustez na captação das nuances acústicas para além do léxico.

4.5 Estratégia de Late Fusion

A combinação das modalidades é feita por **late fusion linear ponderada** ao nível de decisão:

$$\text{score}_{\text{final}}(e) = w_{\text{text}} \cdot \text{score}_{\text{textual}}(e) + w_{\text{prosody}} \cdot \text{score}_{\text{prosódico}}(e)$$

com $w_{\text{text}} = 0.7$ e $w_{\text{prosody}} = 0.3$,
 $\forall e \in \{\text{joy, sadness, anger, fear, disgust, surprise, neutral}\}.$

Fundamentação Matemática e Empírica da Ponderação 70/30

A proporção assimétrica é suportada por múltiplas linhas de evidência da literatura.

Minimização da variância do erro: quando uma modalidade tem confiança estatística superior, a média ponderada deve refletir essa assimetria para produzir um resultado mais estável [6]. Os modelos prosódicos apresentam maior variância *inter-locutor* — o que é um tom “alto” para um locutor pode ser o normal para outro — ao contrário do texto, cuja representação simbólica é normalizada pela língua.

Evidência empírica cross-domínio: estudos em reconhecimento de emoção multimodal demonstram que a proporção 0.7/0.3 produz os melhores resultados em acurácia e robustez [7, 8]. Experimentos com fusão *score-level* em arquiteturas diversas reportam este equilíbrio como ótimo entre confiança na predição principal e incorporação de informação auxiliar.

Valence vs. Arousal: o texto transporta a *valence* emocional (o *quê* é expresso); a prosódia transporta o *arousal* e a intensidade (o *como* é expresso). A proporção 70/30 garante que o sistema compreenda o conteúdo semântico antes de o modular pelo contexto acústico — o caso canónico é o “*estou bem*” dito com voz de choro, onde os 0.3 prosódicos contradizem e corrigem os 0.7 textuais [6].

Modelo de Mehrabian adaptado à IA: Mehrabian [9] propôs que apenas 7% de uma mensagem emocional é transmitida pelas palavras. No entanto, na análise computacional, o texto é o portador de 100% da estrutura lógica — sem o texto, o tom indica irritação, mas não com o quê. A transposição para IA exige que o texto receba peso dominante para garantir compreensão do conteúdo antes da interpretação emocional vocal.

Table 7. Distribuição de pesos texto/áudio em estudos da literatura

Contexto	w_{texto}	$w_{\text{áudio}}$	Conclusão
Sumarização multimodal [7]	0.7	0.3	Otimização empírica — máxima relevância
Reconhecimento de engajamento	dom.	sup.	Texto: precisão; áudio: recall
Biometria híbrida [8]	0.7	0.3	Menor EER e maior robustez
RAG híbrido (busca semântica)	0.7	0.3	Estabilidade semântica superior
Deteção de intenção maliciosa	0.8	0.2	Semântica como melhor indicador

Vantagens da Late Fusion: (1) **modularidade** — os modelos Semântico (LLM) e Prosódico são substituíveis independentemente; (2) **interpretabilidade** — os pesos 0.7/0.3 tornam auditável qual modalidade contribuiu para cada predição; (3) **resiliência** — áudio corrompido com transcrição válida permite normalizar o peso textual para 1.0 [6].

4.6 Motor de Recomendações com Mistral-7B

O motor de recomendações adota uma **pipeline generativa com tolerância a falhas**:

1. **Geração por LLM:** Mistral-7B (Hugging Face Inference API) recebe todo o perfil emocional do utilizador (emoção dominante, volatilidade, e contexto transcrito) no *prompt* e gera estruturalmente 3 atividades únicas, estipulando a duração, intensidade e um *rationale* 100% personalizado em Português.
2. **Filtro de redundância:** Atividades que já tenham sido sugeridas ao utilizador nos últimos 3 dias são incluídas numa lista de exclusão enviado ao LLM e adicionalmente filtradas no pós-processamento, garantindo variedade nas sugestões.
3. **Fallback:** Em caso de falha ou timeout da API, o sistema tem tolerância a falhas através de uma pool local de 5 atividades (diário, *mindfulness*, etc.). Estas são filtradas consoante a emoção dominante do dia.

Justificação da Escolha do Mistral-7B

Embora a docente tenha sugerido modelos alternativos de referência — nomeadamente MadLLaMA e outros modelos da família recomendada — a equipa

optou pelo **Mistral-7B** via Hugging Face Inference API por um conjunto de razões técnicas e pragmáticas:

1. **Disponibilidade via API sem GPU local:** o Mistral-7B está disponível gratuitamente através da Hugging Face Inference API, eliminando a necessidade de infraestrutura GPU dedicada. Os modelos alternativos recomendados exigiriam *self-hosting* ou acesso pago a serviços externos, tornando a integração mais complexa no contexto de um projeto acadêmico.
2. **Qualidade de geração em Português:** o Mistral-7B demonstra capacidade de geração de texto coerente e contextualizado em Português, adequada para produzir racionais de recomendações personalizadas. Modelos mais especializados como MadLLaMA, apesar do seu foco em contexto lusófono, apresentam menor acessibilidade e documentação para integração via API.
3. **Licença open-source e reprodutibilidade:** o Mistral-7B é distribuído sob licença Apache 2.0, garantindo reprodutibilidade do projeto e ausência de restrições de uso acadêmico. Esta característica é relevante para um sistema de bem-estar que lida com dados pessoais sensíveis, onde a transparência do modelo é valorizada.
4. **Robustez do ecossistema:** a integração via Hugging Face Inference API beneficia de documentação extensa, SDKs estáveis e garantias de disponibilidade de serviço. Para um sistema com fallback determinístico implementado, a fiabilidade da API é prioritária relativamente à especialização linguística do modelo.

Em suma, a escolha do Mistral-7B representa um equilíbrio entre qualidade de geração, acessibilidade técnica e viabilidade de implementação no contexto do projeto, sem comprometer os objetivos funcionais do motor de recomendações.

5 Tecnologias e Arquitetura de Software

Table 8. Stack tecnológica e justificação das escolhas

Componente	Tecnologia	Justificação
Frontend	Next.js 15 + React	SSR, TypeScript, hot-reload; padrão industrial para SPAs
API REST	Node.js + Express + TypeScript	Ecossistema JS/TS unificado; BullMQ para filas; Prisma ORM
Análise IA	Python + FastAPI	Ecossistema Python dominante em ML/NLP; API assíncrona
STT	Whisper (OpenAI)	SOTA multilingue; suporte nativo a Português
NLU (Texto)	Ollama + Qwen2.5-3B	LLM executado localmente; alta capacidade de raciocínio emocional em PE
Prosódia	librosa + WavLM-base + SVC RBF	librosa: features interpretáveis; WavLM: embeddings acústicos robustos; SVC RBF: classificação emocional probabilística
LLM (Recs)	Mistral-7B via HF API	Open-source; Inference API elimina GPU local
Base de dados	PostgreSQL + Prisma	RDBMS robusto; Prisma garante type-safety e migrations
Fila de tarefas	Redis + BullMQ	Desacopla upload de processamento; suporta retry
Armazenamento	MinIO (S3-compatible)	Self-hosted; compatível com AWS S3
Orquestração	Docker Compose	Ambiente reproduzível e isolado para todos os serviços

Alternativas consideradas: XLM-RoBERTa vs. Qwen2.5 via Ollama (escolhido Ollama pela fluidez com texto complexo em Português e capacidade de *reasoning*); REST polling vs. WebSockets (polling por simplicidade, com auto-refresh ao completar análise); WavLM-base + SVC RBF para classificação prosódica, com features librosa mantidas para interpretação e fallback.

6 Implementação do Sistema

6.1 Fluxo de Análise

1. Utilizador grava áudio no frontend e submete via formulário multipart.
2. A **api** persiste o ficheiro no MinIO, cria registo **Journal** com estado **pending** e enfileira tarefa no Redis.
3. O **api-worker** consome a tarefa e invoca o serviço **analysis** via HTTP POST.
4. O **analysis** executa: (a) transcrição com Whisper large-v3-turbo, (b) extração de features acústicas com librosa, (c) extração de embeddings WavLM-base, (d) classificação prosódica com SVC RBF, (e) inferência textual com Qwen2.5 via Ollama usando **Light_Ensemble_Disambiguated**.
5. O **analysis** combina as distribuições textual e prosódica por late fusion ponderada, produzindo uma distribuição final sobre sete emoções.
6. O **analysis** notifica a **api** via callback com a transcrição, vetor emocional final, scores semânticos, scores prosódicos, emoção dominante e confiança final.
7. A **api** atualiza o **Journal** na base de dados com os scores emocionais e estado **complete**.
8. O frontend deteta **complete** por polling e atualiza automaticamente a timeline, o gráfico de tendências e o calendário emocional.

6.2 Sistema de Persistência

Três entidades principais: **Journal** (entrada de voz com transcrição, scores emocionais e status), **DailyTrend** (agregação diária de scores médios e volatilidade emocional) e **Recommendation** (atividade gerada para um dia, com rationale, confiança, feedback e data de conclusão).

Os serviços da arquitetura são:

Table 9. Serviços da arquitetura MoodTrackAI

Serviço	Porto	Responsabilidade
frontend	5173	Interface Next.js; captura de áudio; visualização de tendências e recomendações
api	3000	API REST principal; journals, utilizadores, recomendações; orquestra a fila
api-worker	interno	Consumidor BullMQ; invoca o serviço Python; atualiza journal na BD
analysis	8000	FastAPI; STT Whisper large-v3-turbo; Qwen2.5 via Ollama; WavLM-base + SVC; late fusion
ollama	11434	Servidor de inferência LLM dedicado, hospedando o modelo textual
postgres	5432	BD relacional: journals, tendências diárias, recomendações
redis	6379	Fila BullMQ; cache de estado de análise
minio	9000	Armazenamento de ficheiros áudio (S3-compatible)

6.3 Interface Web

A interface usa **dark mode**, tipografia Inter e paleta azul-violeta. As três secções principais estão ilustradas nas figuras seguintes.




Fig. 2. Painel de Captura — timer de gravação, botões de controlo e estado em tempo real.



Fig. 3. Painel de Tendências — gráfico de linhas multi-emoção e calendário emocional mensal.




Fig. 4. Painel de Recomendações — cards com atividades, tabs Hoje/Histórico e feedback.

6.4 Reprodutibilidade

O repositório inclui um ficheiro `README.md` com instruções completas para instalação e execução do sistema via Docker Compose, incluindo configuração de variáveis de ambiente e download dos modelos Ollama.

7 Exemplos de Utilização e Resultados

7.1 Validação Final com Áudios de Demonstração

Para validar a integração ponta-a-ponta, foram gravados sete áudios de teste, um por classe emocional, utilizando relatos curtos em Português Europeu. Cada áudio foi processado pela pipeline completa: transcrição Whisper, classificação textual Qwen2.5, classificação prosódica WavLM-base + SVC e late fusion final.

Table 10. Resultados da validação final com áudios de demonstração processados pela pipeline multimodal completa

Áudio	Classe esperada	Classe final prevista
anger.wav	anger	anger
disgust.wav	disgust	disgust
fear.wav	fear	fear
joy.wav	joy	joy
neutral.wav	neutral	neutral
sad.wav	sadness	sadness
surprise.wav	surprise	surprise

A versão inicial da pipeline confundia alguns relatos negativos com **sadness**. Após a introdução da camada **Light_Ensemble_Disambiguated**, os casos de **anger** e **fear** passaram a ser corretamente classificados, mantendo corretos os restantes casos. Esta validação não substitui uma avaliação estatística com corpus anotado, mas demonstra o funcionamento end-to-end da aplicação em cenários controlados de demonstração.

7.2 Cenário 1 — Predominância de tristeza

O utilizador grava “*Hoje foi um dia difícil. Senti-me cansado e sem motivação...*”. O modelo textual atribui **sadness** = 0.76 e **fear** = 0.42; a prosódia confirma pitch baixo, taxa de fala reduzida e **pause_ratio** elevada. Vetor fundido: {joy: 0.05, sadness: 0.76, anger: 0.04, fear: 0.11, disgust: 0.05, surprise: 0.15}. Recomendações: Caminhada nas Ondas do Mar, Desenho com Sombras, Yoga, conforme ilustrado nas Fig. 5 e Fig. 6.




Fig. 5. Resultados da gravação, após late fusion




Fig. 6. Recomendações após a mesma gravação

7.3 Cenário 2 — Surpresa positiva

O utilizador grava “*Hoje recebi uma notícia completamente inesperada. Fui selecionado por uma oportunidade que não esperava. Fiquei sem palavras, muito contente e agitado ao mesmo tempo.*”. O modelo textual deteta $\text{joy} = 0.53$ como emoção dominante e $\text{surprise} = 0.32$ como secundária; a prosódia confirma taxa de fala elevada e energia acima da média. O vetor fundido resultante é $\{\text{joy}: 0.53,$

sadness: 0.06, anger: 0.10, fear: 0.17, disgust: 0.05, surprise: 0.32}, conforme ilustrado na Fig. 7.




Fig. 7. Resultados da gravação

8 Discussão Crítica

8.1 Limitações Técnicas

- O Whisper large-v3-turbo, apesar de robusto, pode apresentar degradação em sotaques regionais, ruído de fundo ou fala muito hesitante.
- Modelos LLM como o Qwen2.5 dependem fortemente da qualidade dos prompts e podem produzir respostas JSON inválidas ou distribuições excessivamente confiantes, exigindo parsing robusto e normalização.
- O modelo prosódico WavLM-base + SVC foi treinado em dados emocionais controlados, podendo sofrer *domain shift* quando aplicado a gravações espontâneas de diário.
- A prosódia é mais instável entre locutores do que a componente textual, pelo que foi usada como sinal complementar e não como classificador dominante.
- A ausência de datasets emocionais amplos em Português Europeu limita a validação quantitativa rigorosa do sistema ponta-a-ponta.
- A execução local de Whisper, WavLM e Ollama exige recursos computacionais relevantes, podendo aumentar a latência em máquinas sem GPU.

8.2 Viés Algorítmico

- **Whisper:** treinado maioritariamente em conteúdo online; pior desempenho para sotaques regionais e disfluências.

- **LLMs / Qwen2.5:** a sua capacidade de reconhecer emoções foi destilada a partir de textos da internet (maioritariamente anglo-saxónica). Expressões culturais e coloquialismos típicos de Portugal podem não gerar o impacto emocional esperado na rede.
- **WavLM/SVC:** embora WavLM forneça representações acústicas robustas, o classificador prosódico foi treinado em dados emocionais que podem não refletir totalmente a expressividade vocal espontânea em Português Europeu. Isto pode introduzir viés cultural, linguístico e de locutor.

8.3 Limitações da Interpretação Automática

A análise automática de emoções não deve ser interpretada como diagnóstico clínico. O sistema identifica padrões linguísticos e acústicos associados a categorias emocionais em corpus, mas não tem acesso ao contexto subjetivo, histórico clínico ou intenção comunicativa do utilizador. A emoção inferida é uma estimativa estatística, não uma leitura objetiva do estado interno.

9 Considerações Éticas

9.1 Privacidade e Consentimento

O áudio de voz é um dado biométrico sensível. O sistema usa MinIO self-hosted e LLMs locais (Ollama) para evitar partilha de relatos textuais e de voz com servidores cloud de terceiros. Num contexto de produção real seriam necessários: consentimento informado explícito, política de retenção e direito ao esquecimento (RGPD), encriptação em repouso e em trânsito, e anonimização antes de análise de grupo.

9.2 Uso Responsável

O sistema foi concebido como ferramenta de apoio ao bem-estar e não como instrumento clínico.

10 Conclusão e Trabalho Futuro

10.1 Conclusão

O MoodTrackAI demonstra a viabilidade de um sistema end-to-end de análise emocional multimodal aplicado ao diário de voz em Português Europeu. A arquitetura de microsserviços garantiu separação de responsabilidades e execução reproduzível via Docker Compose. A componente textual, baseada em Qwen2.5 executado localmente via Ollama e na estratégia `Light_Ensemble_Disambiguated`, revelou-se particularmente eficaz na interpretação semântica de relatos espontâneos. A componente prosódica, baseada em WavLM-base + SVC RBF, acres-

centou informação vocal complementar, permitindo uma abordagem multimodal mais rica do que a análise textual isolada.

A late fusion probabilística, com pesos base de 70% para texto e 30% para áudio, permitiu combinar as modalidades de forma interpretável e modular. A inclusão da classe **neutral** tornou o sistema mais adequado a entradas reais de diário, onde muitos relatos são factuais ou emocionalmente pouco marcados. Apesar das limitações inerentes à ausência de um corpus anotado em Português Europeu, os testes finais demonstraram o funcionamento completo da pipeline desde a gravação do áudio até à apresentação de tendências e recomendações personalizadas.

10.2 Trabalho Futuro

- **Avaliação quantitativa:** construir ou recolher um corpus anotado em Português Europeu para avaliar separadamente a componente textual, a componente prosódica e a late fusion.
- **Otimização da prosódia:** testar modelos acústicos alternativos, afinação supervisionada de WavLM e normalização por locutor para reduzir variabilidade individual.
- **Otimização de prompts:** expandir a estratégia `Light_Ensemble_Disambiguated` com mais exemplos *few-shot* de coloquialismos de Portugal e casos ambíguos.
- **WebSockets:** substituir polling por notificações em tempo real para atualização instantânea do frontend.
- **Aplicação móvel:** iOS/Android com gravação nativa e notificações push para lembretes diários.
- **Análise longitudinal:** deteção de padrões semanais/sazonais e alertas proativos quando a volatilidade emocional persiste por múltiplos dias.

References

1. Picard, R.W.: Affective Computing. MIT Press, Cambridge, MA (2000).
2. Tian, L., Oviatt, S., Muszynski, M., Chamberlain, B., Healey, J., Sano, A.: Applied Affective Computing. *ACM Transactions on Interactive Intelligent Systems*. 12, (2022).
3. Ekman, P.: An Argument for Basic Emotions. *Cognition & Emotion*. 6, 169–200 (1992).
4. Verma, G.K.: Multimodal Affective Computing: Affective Information Representation, Modelling, and Analysis. Springer (2023).
5. Radford, A., Kim, J.W., Xu, T., Brockman, G., McLeavey, C., Sutskever, I.: Robust Speech Recognition via Large-Scale Weak Supervision. In: *International Conference on Machine Learning (ICML)* (2023).
6. Morency, L.-P., Mihalcea, R., Doshi, P.: Towards Multimodal Sentiment Analysis: Harvesting Opinions from the Web. In: *Proceedings of the 13th International Conference on Multimodal Interfaces (ICMI)*. pp. 169–176. ACM (2011).
7. Poria, S., Cambria, E., Hazarika, D., Majumder, N., Zadeh, A., Morency, L.-P.: Context-Dependent Sentiment Analysis in User-Generated Videos. In: *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (ACL)*. pp. 873–883 (2017).
8. Zadeh, A., Chen, M., Poria, S., Cambria, E., Morency, L.-P.: Tensor Fusion Network for Multimodal Sentiment Analysis. In: *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. pp. 1103–1114 (2017).
9. Mehrabian, A.: *Silent Messages: Implicit Communication of Emotions and Attitudes*. Wadsworth, Belmont, CA (1971).